МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

по курсу

«Data Science»

Применение алгоритмов глубокого обучения к задачам шумопонижения изображений

Слушатель Лаврентьев Василий Юрьевич

Москва, 2023

Содержание

Введение

Одной из особенностью устройств цифровой регистрации изображений является тот факт, что из-за несовершенства систем формирования изображения, средств регистрации и передачи, цифровые изображения содержат не только полезную информацию (собственно, изображение), но некоторые случайные искажения, вносимые, как самим светочувствительным сенсором, так и электронными компонентами устройств. Такие искажения сигнала носят названия шума – дефекта изображения, проявляющегося в виде случайным образом расположенных точек, имеющих размеры, близкие к размерам пикселя и интенсивность, отличающуюся от интенсивности полезного сигнала.

В ряде случаев, при хороших условиях съемки и отсутствии каких-либо особых требований к качеству изображения подобный шум не вносит сколь нибудь значимых изменений в итоговое изображение и, чаще всего, просто игнорируется, однако при плохих условиях съемки, а также в случаях, когда к получаемому результату предъявляются определенные требования шум на получаемом изображении может приводить к серьезному ухудшению качества последнего и потребуется применение мер для снижения его уровня.

Таким образом, очистка от шума является одной из основных задач цифровой обработки изображений. Актуальность этой задачи в современных условиях повсеместного распространения цифровых фотокамер, смартфонов, камер видеонаблюдения и других аналогичных устройств возрастает многократно. Особую актуальность задача принимает в случаях практического применения компьютерного зрения, сегментации, распознавания образов и классификации, т.к. загрязнение исходного изображения шумом напрямую влияет на качество работы алгоритмов и получаемые результаты.

Целью данной работы является обзор применения ряда архитектур нейронных сетей к задачам снижения шумов на изображении и их сравнительный анализ; автором работы таже предложен новый подход,

модифицирующий алгоритм на этапе формирования зашумленных изображений и позволяющий получить картину шума, близкую к реальной.

1 Аналитическая часть

1.1 Постановка задачи

В данной работе рассматривается задача очистки цифровых изображений от шумов с применением алгоритмов, основанных на использовании нейронных сетей. К настоящему времени существует множество методов, реализующих различные архитектуры нейронных сетей и позволяющих в той или иной мере решить данную задачу. Помимо этого, существуют классические методы шумоподавления, такие как линейное усреднение по соседним пикселям, медианный фильтр, вейвлет-преобразования и др.

В рамках данной работы будут рассмотрены несколько архитектур: автоэкодер, DNCNN, Unet.

В качестве исходных данных использован набор изображений Imagenet; в целях ускорения процесса обучения данный датасет использован не в полном объеме: для обучающей и тестовой выборок взяты 2.500 изображений (2000 – обучающая,500 – тест), для валидационной выборки – 1000. Все изображения приведены к размеру (256,256,3) с сохранением пропорций, значения интенсивности в каждом канале приведены к диапазону [0, 1].

Формирование зашумленных изображений производилось путем добавления к исходным изображениям гауссова шума (среднее значение – 0, стандартное отклонение – 1). В целях формирования более реальной картины, конкретный уровень шума, добавляемый к каждому из изображений, определялся дополнительным множителем, выбираемым случайным образом из диапазона [0.1, 0.3].

Для оценки качества работы алгоритмов применялись следующие показатели: пиковое отношение сигнал-шум (PSNR, peak signal to noise ratio):

$$PSNR = 10 \log_{10} \frac{MAX_I^2}{MSE} \quad (1)$$

где MSE – среднеквадратичное отклонение,

и индекс структурного сходства (SSIM, structural similarity index measure):

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + c_1)(2\sigma_{xy} + c_2)}{(\mu_x^2+\mu_y^2 + c_1)(\sigma_x^2 + \sigma_y^2 + c_2)}, \quad (2)$$

где

μ_x, μ_y – средние значение первого и второго изображение соответственно,

σ_x, σ_y – среднеквадратичные отклонения,

σ_{xy} – ковариация,

c_1, c_2 – поправочные коэффициенты, определяемые как

$$c_1 = (0.01L)^2, c_2 = (0.03L)^2, \quad (3)$$

где L – динамический диапазон изображения.

Для расчета данных показателей будем использовать методы psnr() и ssim() из библиотеки tensorflow.

В качестве эталонного использовалось исходное незашумленное изображение. Финальные показатели рассчитывались как усредненные значения по всей валидационной выборке.

В качестве функций потерь были опробованы: *MAE*, *MSE* и комплексный показатель, основанный на [] *SSIM_L2*, рассчитываемый как

$$SSIM\_L2 = (1 - SSIM) + MSE \quad (4)$$

Обучение моделей, построенных в ходе выполнения работы производилось на ПК с процессором AMD Atlon X6, 32 Гб ОЗУ и графическим ускорителем Nvidia RTX 3060 в среде Jupyter Notebook. Часть экспериментов проводилась с использованием ресурсов Kaggle.

1.2 Обзор использованных архитектур

1.2.1 Автоэнкодеры

Автоэнкодер – нейронная сеть прямого распространения, которая восстанавливает входной сигнал на выходе (рисРисунок 1 - Автоэнкодер).

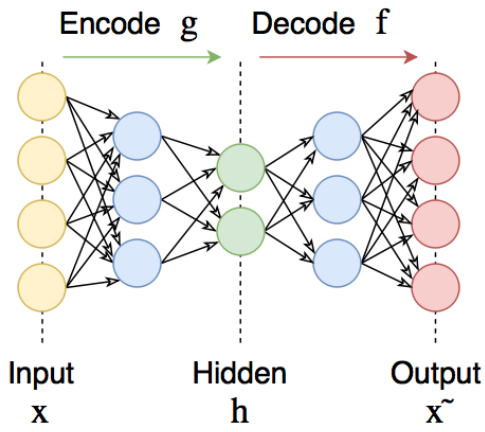

Рисунок 1 - Автоэнкодер

Автоэнкодеры сжимают входные данные для представления их в latent-space (скрытое пространство), а затем восстанавливают из этого представления output (выходные данные). Цель — получить на выходном слое отклик, наиболее близкий к входному. Автоэнкодеры конструируются таким образом, чтобы не иметь возможность точно скопировать вход на выходе. Обычно их ограничивают в размерности латентного (скрытого) пространства. Входной сигнал восстанавливается с ошибками из-за потерь при кодировании, но, чтобы их минимизировать, сеть вынуждена учиться отбирать наиболее важные признаки и отбрасывать несущественные; именно эта особенность является ключевой для применения архитектуры автоэнкодеров к задачам шумоподавления изображений: на вход подается зашумленное изображение, на выходе сеть пытается построить изображение, очищенное от шума.

1.2.2 dnCNN

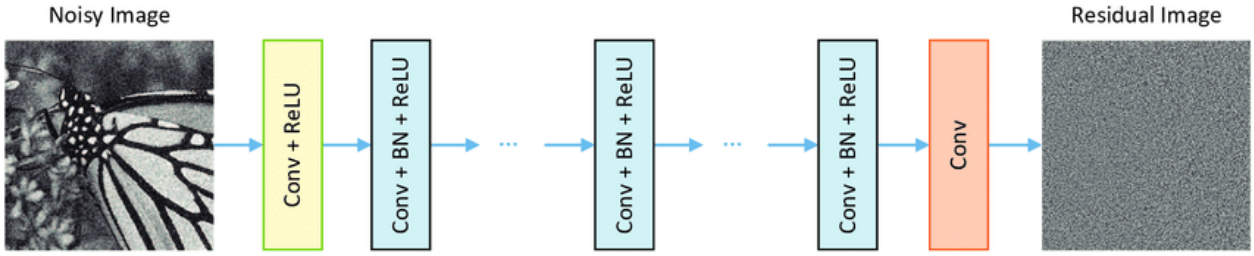

Рисунок 2 - Оригинальная архитектура dnCNN

Предложенная в [] архитектура dnCNN представляет собой глубокую сверточную сеть, имеющую на входе Conv+Relu слой и N блоков Conv+BN+Relu далее (рис). Последний сверточный слой сети представляет собой Conv блок с размерностью 3 для соответствия входному изображению. На выходе сеть формирует «residual image» (по сути шумовая карта), которое на выходе сети вычитается из входного сигнала и в итоге дает изображение, очищенное от шума. В оригинальной работе каждый из блоков содержал Conv слой с 64 фильтрами и ядром 3x3. Входной слой также имел Conv 64x3x3. Функция активации – Relu, функция потерь – MSE. Инициализация весов - Xavier initialization [].

1.2.3 Unet

U-Net - это сверточная нейронная сеть, разработанная для сегментации изображений. Она была представлена в статье "U-Net: Convolutional Networks for Biomedical Image Segmentation" в 2015 году [] и была изначально предназначена для сегментации медицинских изображений. U-Net позволяет точно выделять объекты на изображении и является основой для многих приложений в области компьютерного зрения и медицины.

Сеть содержит сверточную (слева) и развертночную части (справа), поэтому архитектура похожа на букву U, что и отражено в названии. На каждом шаге количество каналов признаков удваивается.

Сверточная часть похожа на обычную свёрточную сеть, содержит два подряд свёрточных слоя 3×3, после которых идет слой ReLU и пулинг с функцией максимума 2×2 с шагом 2.

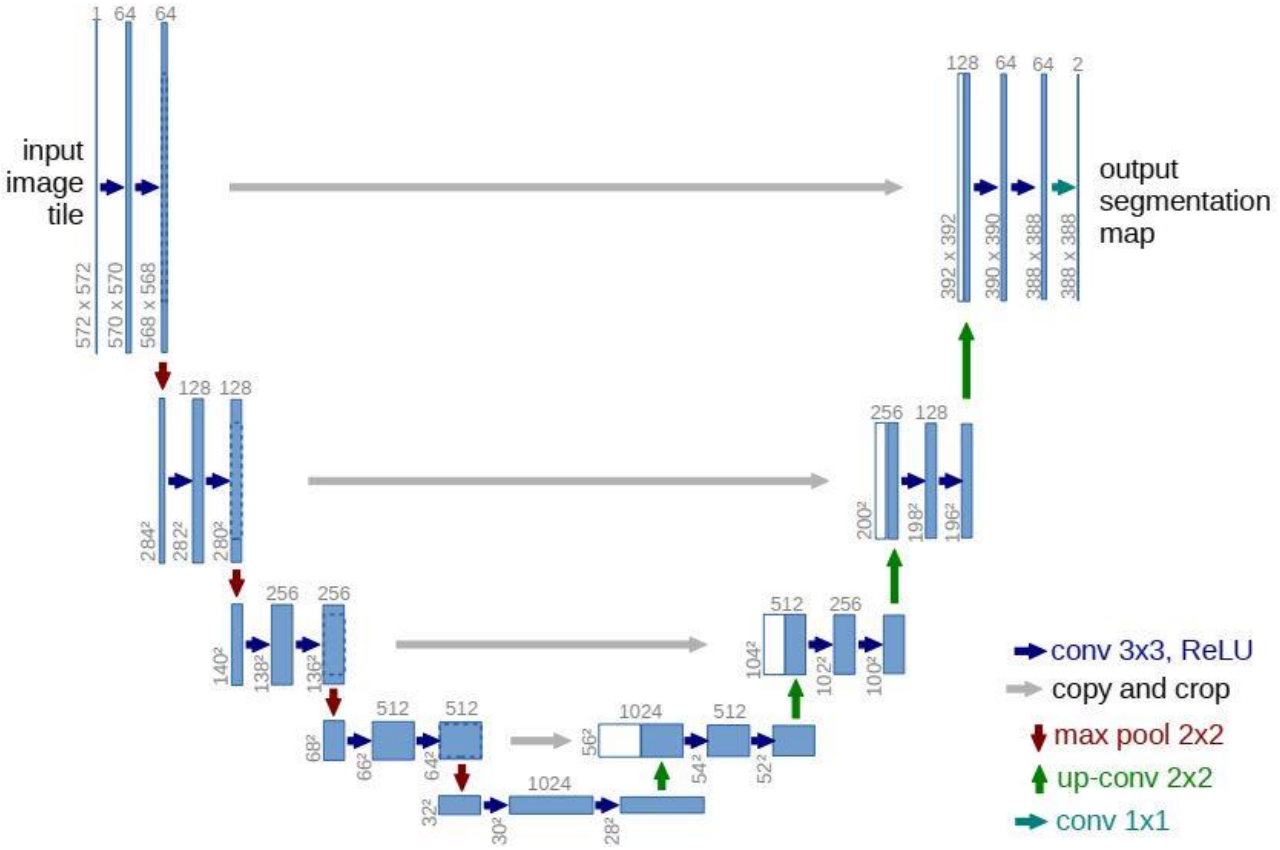

Рисунок 3 - Архитектура Unet

Каждый шаг разверточной части содержит слой, обратный пулинг, который расширяет карту признаков, после которого следует свертка 2×2, которая уменьшает количество каналов признаков. После идет конкатенация с картой признаков из сжимающего пути и две свертки 3×3, после каждой из которой идет ReLU. На последнем слое свертка 1×1 используется для приведения каждого 64-компонентного вектора признаков до требуемого количества классов.

Всего сеть имеет 23 свёрточных слоя.

Несмотря на то, что архитектура изначально предназначалась для задач сегментации, существует множество ее реализаций применительно и к другим

задачам обработки изображений (снижение шумов, восстановление, повышение разрешения и др.), как в качестве самостоятельной сети, так и в виде блока генератора в GAN.

2 Практическая часть

2.1 Методология

Работа состояла из трех этапов. На первом этапе проводились эксперименты с целью подбора наиболее оптимальных параметров для каждой из сетей – тестовое обучение с числом эпох 30 и уменьшенными размерами обучающей/тестовой выборок (1600 обучение, 400 тест). Были опробованы функции активации: Relu, LeakyRelu, Gelu []; оценка результата производилась по полученным итоговым показателям PSNR, SSIM; также оценивался ход обучения (стабильность процесса обучения, наличие/отсутствие скачков функции потерь, контроль переобучения) и величина ошибки на обучающей/тестовой выборке по завершении обучения. Также на этом этапе проводились эксперименты с модификацией архитектуры в части выбора числа слоев, количества фильтров и т.п. Число слоев сети, число нейронов в слое, количество фильтров в сверточных слоях подбиралось эмпирически. Выбранные таким образом конкретные реализация архитектуры и функции активации использовалась далее для трех тестовых запусков (30 эпох, выборка 1600 обучение, 400 тест) с тремя различными функциями потерь – MAE, MSE, SSIM_L2. Полученные результаты по каждой из построенных архитектур сведены в таблицу 1, как можно видеть во всех трех случаях самое высокое значение SSIM было получено с применением комплексной функции потерь SSIM_L2. Некоторое несоответствие между оценками по PSNR и SSIM связано с особенностями самих показателей – PSNR оценивает соотношение «сигнал-шум» и в некоторых случаях может дать более высокую оценку изображение с более низким уровнем шума, но меньшей детализацией. SSIM же оценивает «степень похожести» и потеря мелких деталей на изображении, равно как и сдвиг цветового баланса» может заметно снизить оценку, при том, что для этого же изображения PSNR такие потери может проигнорировать и дать в результате более высокое значение. Таким образом, оценка результата производилась,

опираясь на значение именно SSIM при учете общего визуального восприятия изображения, а также динамики процесса обучения.

Таблица 1. Результаты тестов первого этапа

Архитектура	**Loss function**	**Результат после 30 эпох**			**Примечание**
		loss	**PSNR**	**SSIM**	
AE	Adamax, mae	loss: 0.0474 - val_loss: 0.0552	22.99	0.62	
	Adamax, mse	loss: 0.0045 - val_loss: 0.0050	23.53	0.64	
	Adamax, ssim+l2	loss: 0.3076 - val_loss: 0.3303	23.03	**0.67**	
dnCNN	Adamax, mae	loss: 0.0427 - val_loss: 0.0480	21.93	0.67	
	Adamax, mse	loss: 0.0035 - val_loss: 0.0060	24.34	**0.69**	
	Adamax, ssim+l2	loss: 0.4657 - val_loss: 0.4881	22.85	**0.69**	40 эпох
res dnCNN	Adamax, mae				
	Adamax, mse				
	Adamax, ssim+l2	loss: 0.2991 - val_loss: 0.3009	23.17	**0.70**	40 эпох
Unet	Adamax, mae	loss: 0.0525 - val_loss: 0.0517	23.10	0.62	40 эпох
	Adamax, mse	loss: 0.0056 - val_loss: 0.0053	23.19	0.61	
	Adamax, ssim+l2	loss: 1.3919 - val_loss: 1.4290	21.32	**0.66**	45 эпох, lr=0,001

Изображения, полученные с использованием каждой из архитектур в варианте, показавшем лучшую оценку по SSIM приведены на рис 4.

Второй этап заключался в обучении каждой из сетей с параметрами, подобранными по результатам выполнения первого этапа. Обучение производилось на большем наборе данных, число эпох – 30 (для некоторых архитектур понадобилось большее число эпох). Показатели PSNR, SSIM рассчитывались по валидационной выборке. Полученные результаты приведены в таблице 2.

Третий этап. Формирование финального результата - сеть, показавшая лучший результат обучена на двух моделях шума – гауссовом шуме и предложенной в данной работе модели реального шума (далее в 2.7). Оценка

результата производилась на валидационной выборке с расчетом PSNR, SSIM, а также на реальных зашумленных изображениях.

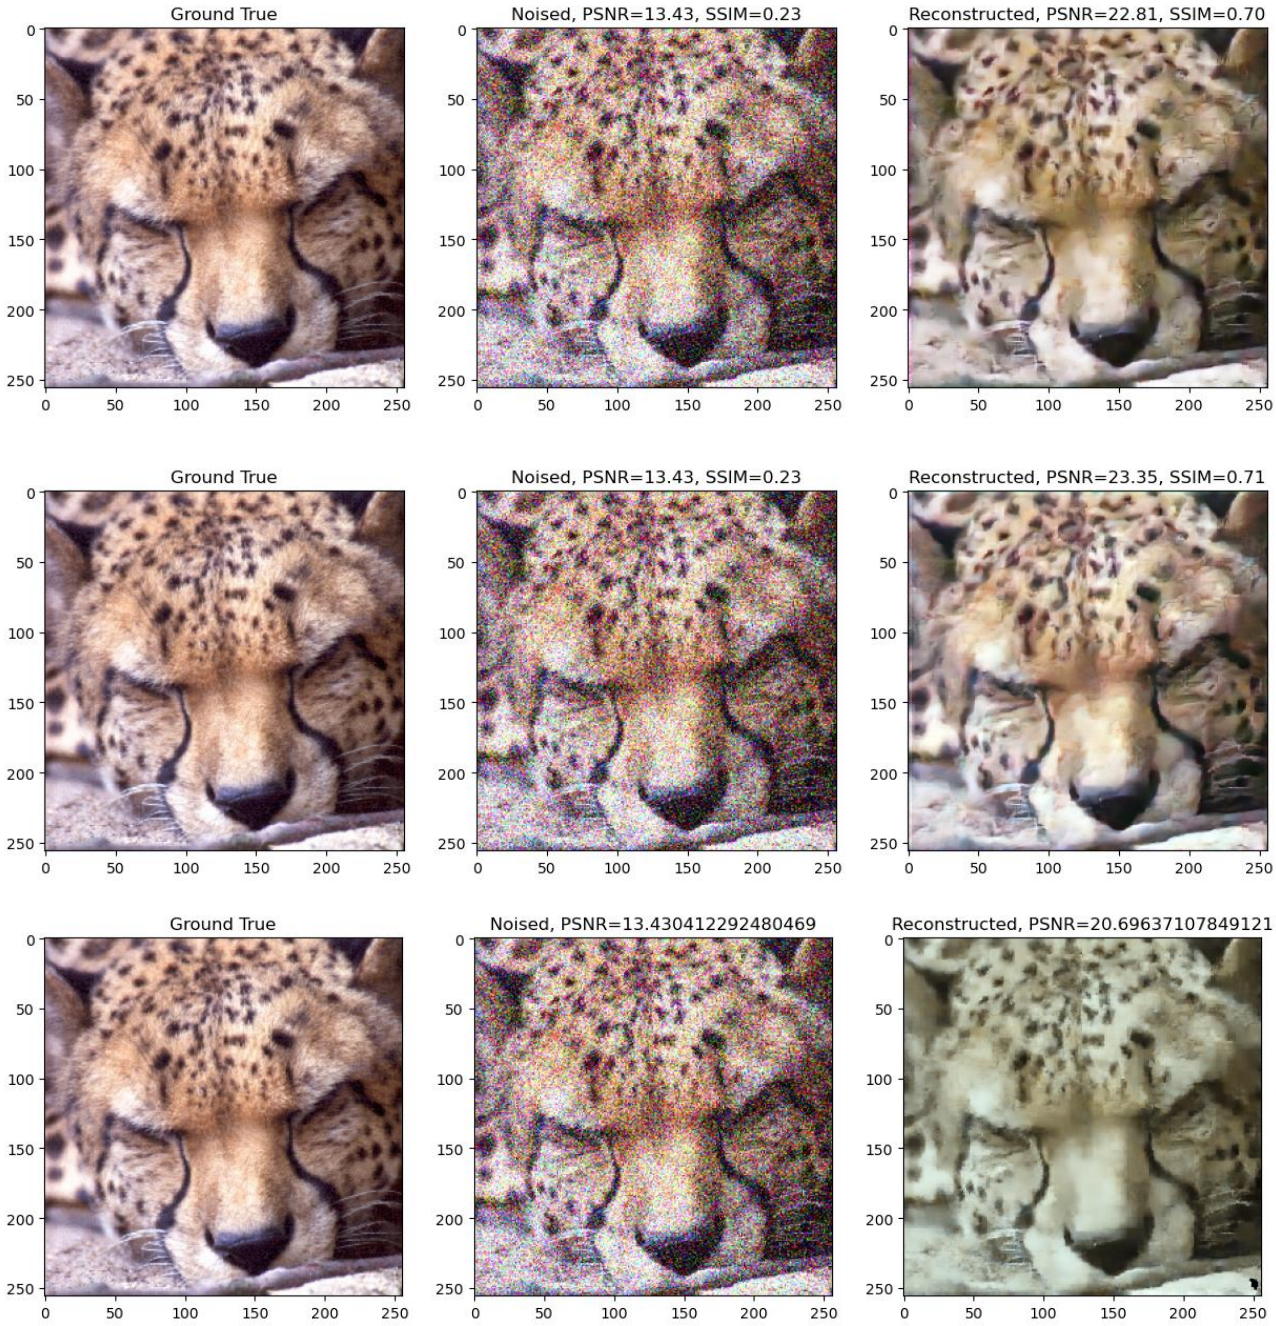

Рисунок 4. Визуальные результаты первого этапа (сверху вниз - автоэнкодер, res dnCNN, Unet)

2.2 Автоэнкодер

Исходный код приведен в файле ae.ipyng

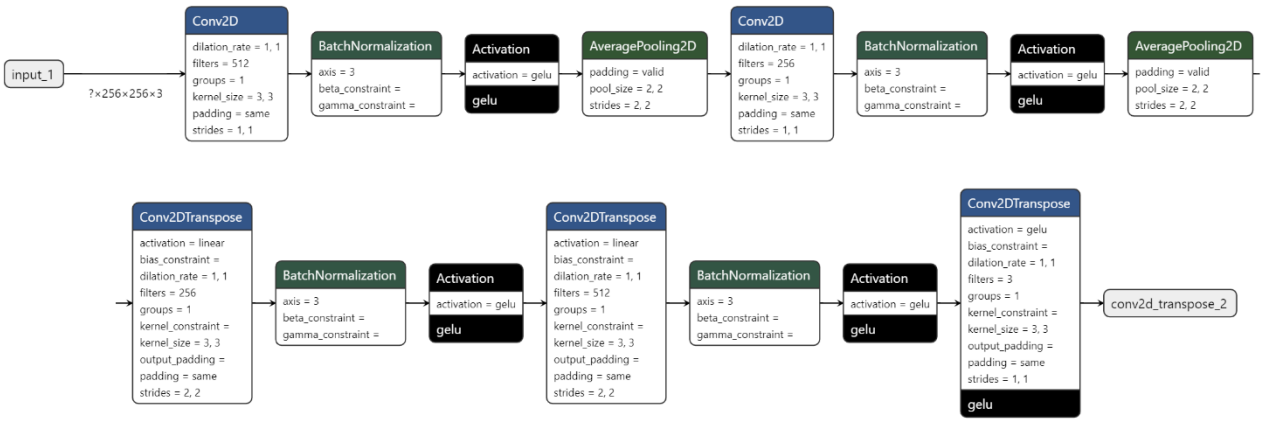

Рисунок 5 - Реализованный автоэнкодер

Реализованный вариант архитектуры изображен на рис 3. Построенная сеть имеет по два сверточных слоя в энкодере и декодере, слои BatchNormalization и слои AveragePooling2D в энкодере. В декодере пулингслои не использованы, а повышение дискретизации выполнено непосредственно в сверточных слоях через задание параметра stride=2. Функция активации – Gelu. Наилучший результат на первом этапе -PSNR 22.71, SSIM 0.67 после 30 эпох обучения.

2.3 dnCNN

Исходный код приведен в файлах dncnn.ipynb, dncnn_res.ipynb.

Реализован вариант архитектуры из оригинальной статьи, число conv блоков (без учета входного и выходного слоев) – 16, инициализация весов xavier не использовалась, функция потерь – SSIM_L2. Наилучший результат первого этапа – PSNR 22.85, SSIM 0.69.

Помимо оригинальной архитектуры в рамках работы была предложена модификация – в каждом из conv блоков добавлены short connection от входа блока на его выход. Остальные слои, функция активации и пр. оставлены без изменений. Схема архитектуры приведена на рис

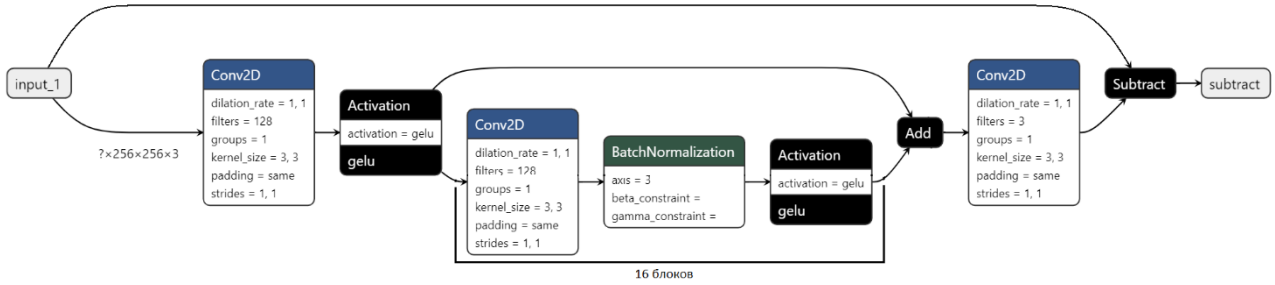

Рисунок 6 – Модифицированный вариант dnCNN

Такое решение позволило несколько улучшить результат, показанный сетью, но при этом пришлось увеличить число эпох обучения до 40: PSNR 23.17, SSIM 0.70

2.4 Unet

Исходный код приведен в файле unet.ipynb

Реализован вариант оригинальной архитектуры с некоторыми изменениями: помимо соединений внутри между соответствующими блоками up и down добавлено соединение (-) от входа на выход; эксперименты показали, что такая модификация показала чуть лучшие результаты – PSNR 21.32, SSIM 0.66. Здесь стоит отметить, что из всех трех рассмотренных сетей Unet в данной задаче показывал наихудший результат, вне зависимости от примененных функций активации и функций потерь; максимальный показатель SSIM, который удалось получить на Unet – 0.66, что несколько меньше, чем показал автоэкодер и заметно меньше, чем удалось получить на модифицированной dnCNN.

Рисунок 7 – Реализация Unet

2.5 Реализация второго этапа

Варианты реализаций, показавшие наилучшие результаты по итогам первого этапа работы обучены на большем объеме исходных данных – 2500 изображений обучение и тест (2000 и 500 соответственно) и 1000 изображений - валидация. Полученные по итогу результаты приведены в таблице 2. Графики процесса обучения приведены на рис. Примеры изображений – на рис 5, 6, 7.

Таблица 2. Результаты тестов второго этапа

Архитектура	Число эпох	Лосс на конец обучения	обучение/тест		валидация	
			PSNR	SSIM	PSNR	SSIM
AE	30	loss: 0.3464 - val_loss: 0.3493	20,18	0,65	20,18	0,63
res dnCnn	40	loss: 0.2930 - val_loss: 0.2914	24,39	0,71	23,51	0,66
unet	45	loss: 0.6286 - val_loss: 0.6450	13,05	0,4	15,01	0,57

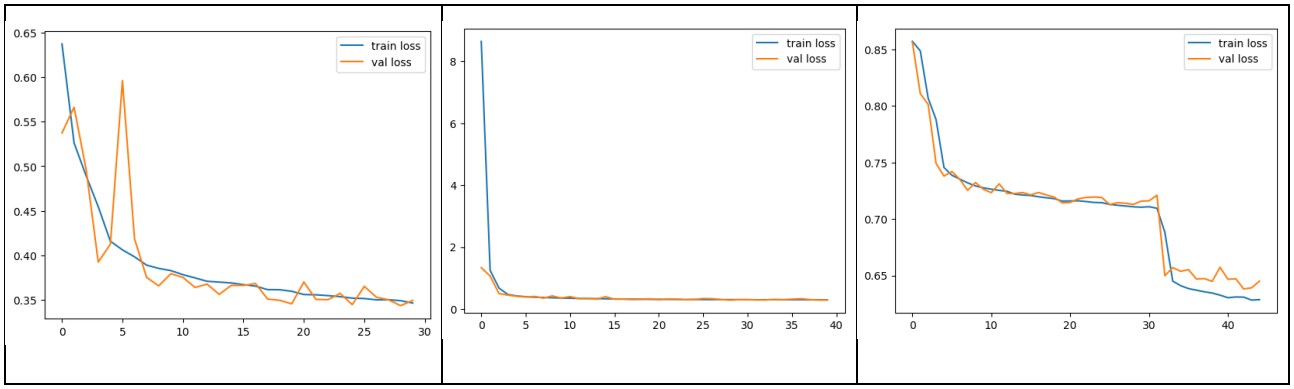

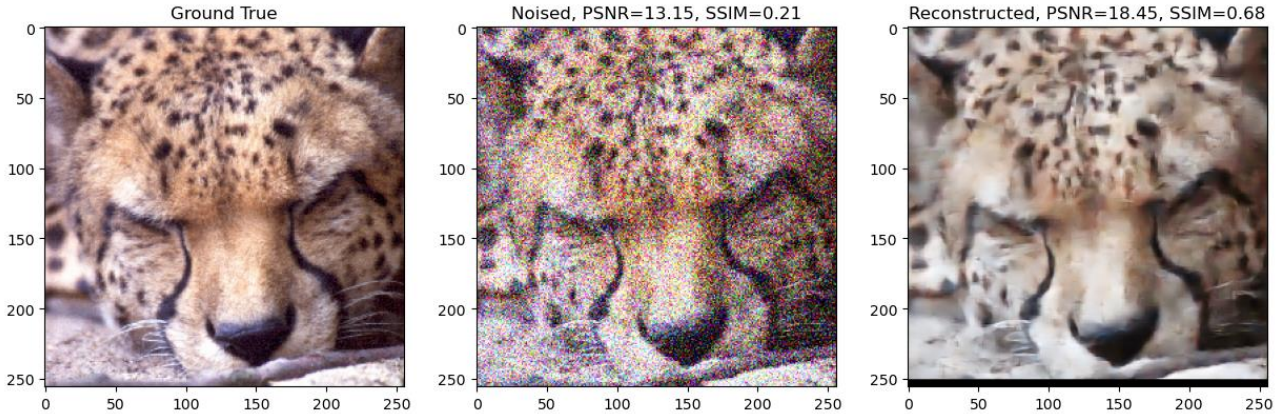

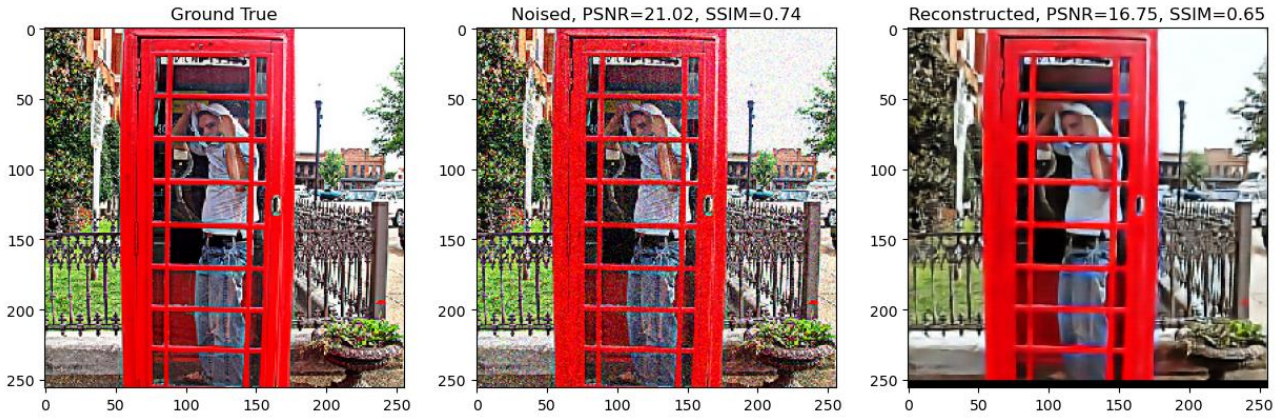

Рисунок 5. Автоэнкодер, обучение/тест вверху, валидация – внизу

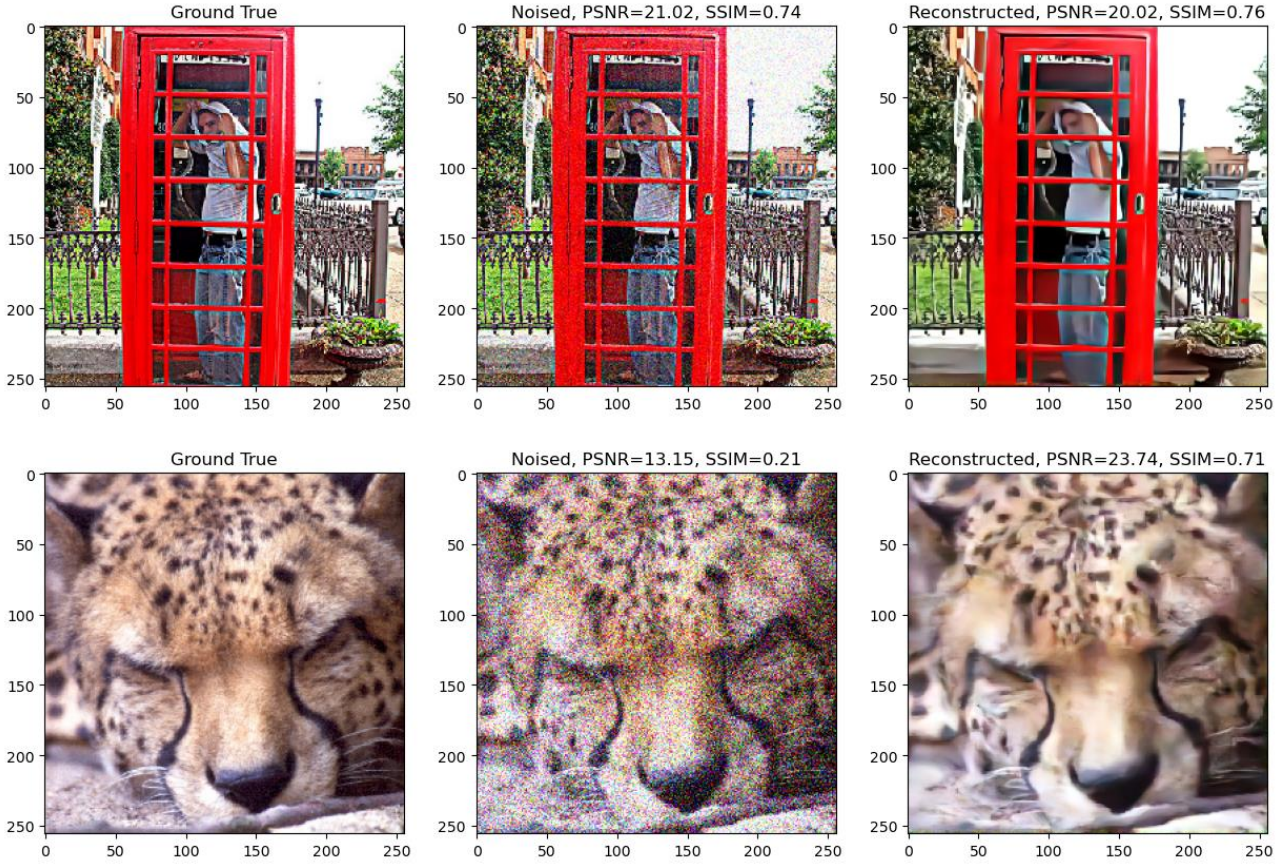

Рисунок 6. Модификация dnCNN – res dnCNN, обучение/тест вверху, валидация – внизу

По итогам второго этапа можно сделать вывод, что наилучшим из рассмотренных вариантов оказалась модификация dnCNN с добавленными short connection во внутренних conv блоках. Данная реализация показала PSNR 20.02

и SSIM 0.76, рассчитанные как среднее по валидационной выборке. При этом стоит отменить, что оценки, полученные на валидации заметно хуже оценок, данных по обучающей и тестовой выборкам. Визуальная оценка полученных восстановленных изображение (рис) показывает заметные локальные размытия изображений и, как следствие, снижение детальности. Учитывая, что признаков переобучения по графикам не выявляется, можно сделать вывод, что обобщающие способности построенных реализаций хуже ожидаемых. Однако, здесь стоит сделать оговорку, что уровень добавленного шума при формировании зашумленного набора данных был выбран достаточно высоким и, как можно видеть из примером изображений, значительная часть мелких деталей скрыта за шумами.

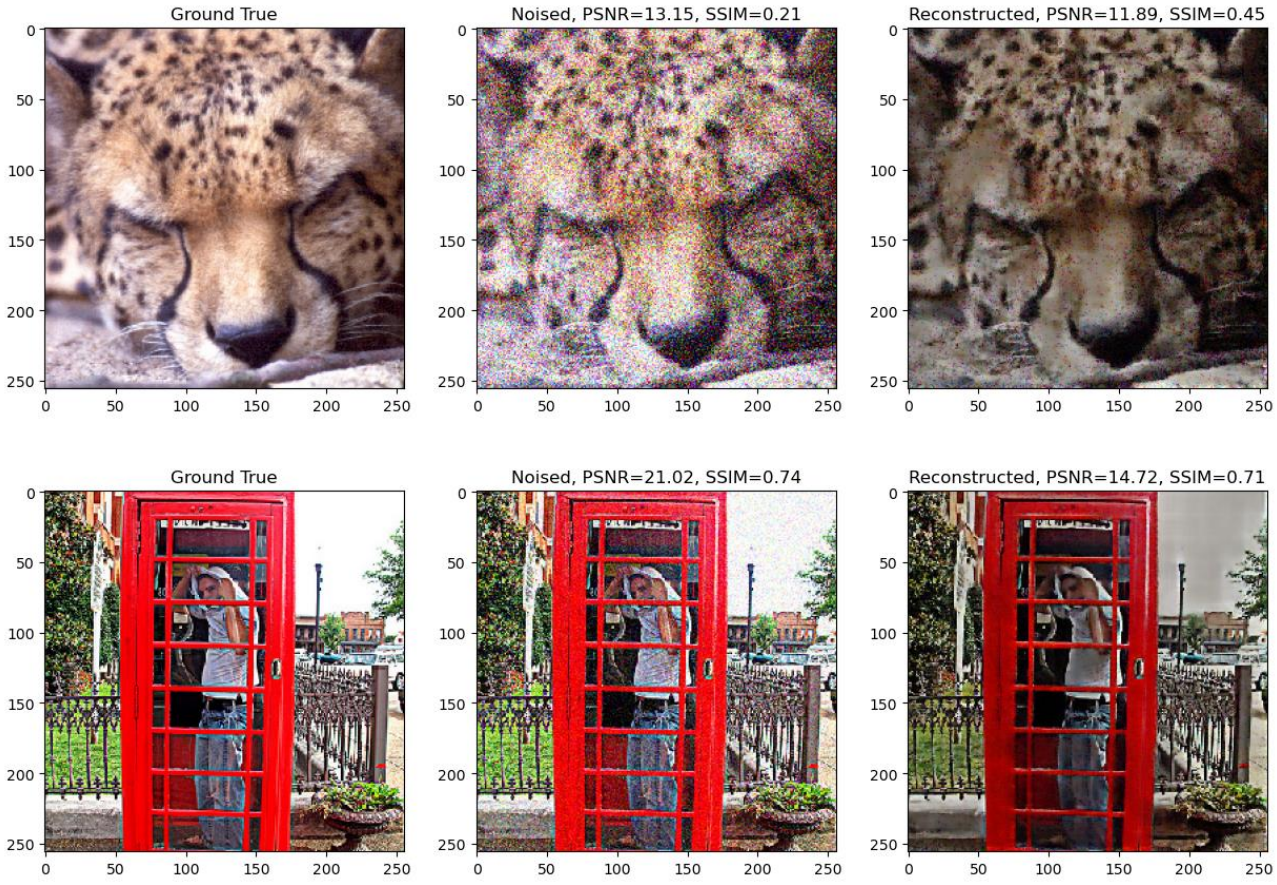

Рисунок 7. Unet, обучение/тест вверху, валидация – внизу

2.6 Построение модели реального шума

Исходный код – файл real_noise.ipynb.

Известно, что алгоритмы шумопонижения, построенные с применением искусственно внесенного шума, при применении их к реальным зашумленным изображениям, как правило, показывает результат хуже ожидаемых; это связано с тем, что реальный шум отличается от искусственно созданного в значительной степени. Принимая во внимание этот факт, в данной работе делается попытка построения модели реального шума и применение этой модели к обучению сети.

2.6.1 Подготовка исходных данных

Исходные данные для построения модели представляют собой 500 цифровых изображений типа «dark», полученных в рамках выполнения данной работы с применением цифровой камеры Canon EOS R. Съемка производилась со снятым объективом и закрытой крышкой сериями по 100 кадров. Между сериями делался (минимально) часовой перерыв для снижения вероятности влияния нагрева сенсора камеры на картину шума. Температура в помещение, где производилась съемка находилась в пределах 20-25 градусов Цельсия. Время экспозиции каждого кадра составляло 1/30 секунды. Выбор именно такого значения обусловлен тем, что в реальных условиях заметный шум на снимках возникает, по причине повышения величины ISO при плохом освещении, а величина 1/30 секунды есть максимально рекомендуемое значение при съемке с рук (выдержки длиннее, вероятнее всего, дадут смаз на фото, выдержки короче – еще более усугубят недостаток света; при этом недостаток экспозиции как раз и компенсируется повышением ISO). Съемка каждой серии производилась при отдельно выбранном значении ISO; таким образом итоговый набор изображений содержит пять поднаборов по 100 кадров со значениями ISO: 400, 640, 1000, 1600, 3200. Для исключения вероятности внесения дополнительных шумов и

артефактов при преобразовании в jpeg сохранение производилось в формате RAW.

2.6.2 Анализ данных

На этапе подготовки данных был собран датасет из 500 RAW-изображений размером 4498x6742. Дальнейший анализ и обработка данных производились в Jupyter Notebook.

Для чтения raw изображений и преобразования их в числовой массив данных была использована библиотека rawpy. Ввиду значительного объема сохранение данных было реализовано в виде отображаемых в память структур numpy memmap. Подготовленный таким образом массив данных для удобства обработки и сокращения объема занимаемой памяти далее был разделен на три массива по числу каналов цветного изображения; таким образом были получены три массива с размерностями (15162758000, 1), и вся дальнейшая работа выполнялась уже с поканальными данными.

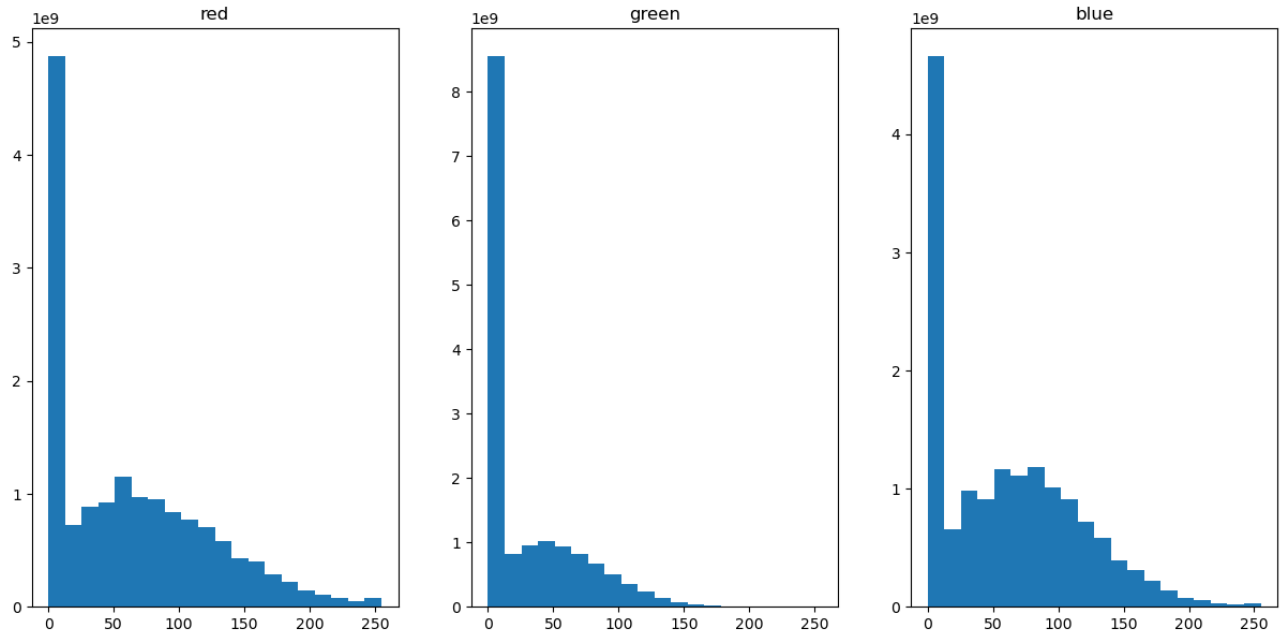

Рисунок 8. Поканальные гистограммы распределения шума

В целях оценки характера распределения и анализа на наличие выбросов были построены гистограммы и диаграммы «ящик с усами» (рис).

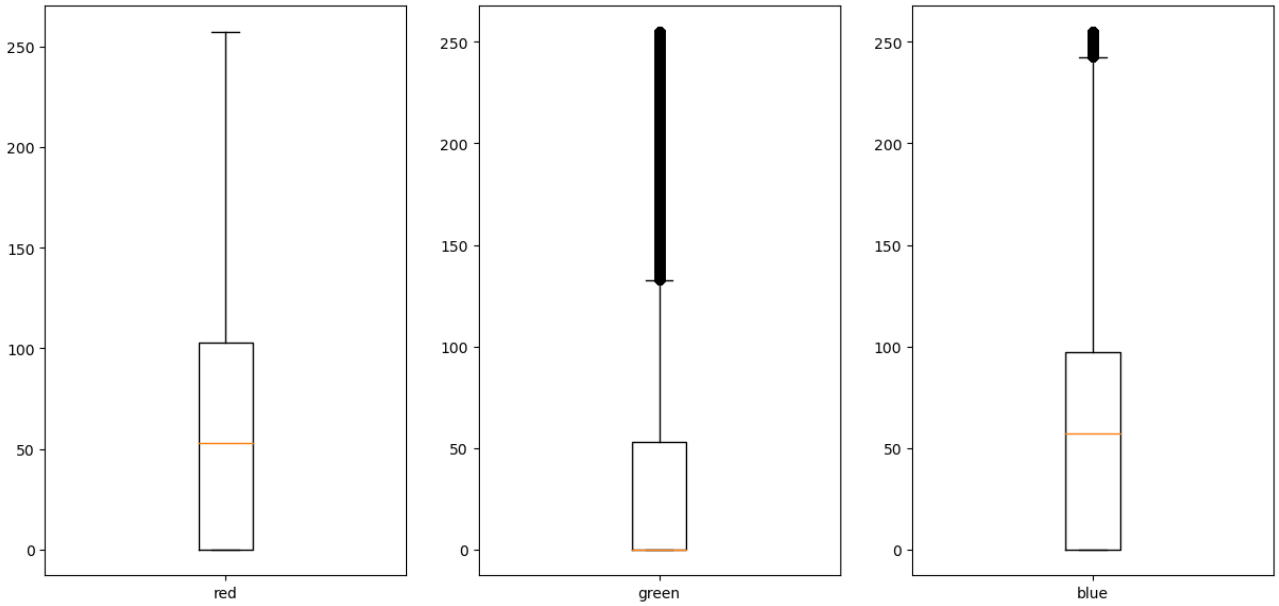

Рисунок 9. Поканальные boxplot распределения шума

По построенной гистограмме (рис. 8) очевидно, что распределение не является нормальным. Анализ диаграммы boxplot (рис. 9) показал отсутствие выбросов в данных в нижней границе и наличие отдельных выбросов в области высоких значений интенсивности; используя правило межквантильных интервалов было произведено удаление выбросов, выходящих за пределы верхнего диапазона $Q3 + 1.5(Q3 - Q1)$, где $Q1, Q3$ – первый и третий квантиль соответственно.

2.6.3 Построения модели и генератора

Подготовленные и очищенные от выбросов исходные данные были использованы для построения эмпирической функции распределения. Идея заключалась в следующем: имея набор значений интенсивности шума получить эмпирическую модель распределения и на ее основе построить генератор, который можно будет использовать для генерации шума при формировании

обучающей выборки; поскольку в основе модели лежат реальные данные, можно сделать предположение о том, что значения, выдаваемые генератором, будут соответствовать реальному распределению шума.

Для реализации идеи из имеющихся исходных данные необходимо получить частоты встречаемости каждого из значений интенсивности, далее рассчитать вектор значений и вектор вероятностей и подать их на вход метода scipy.stats.rv_discrete. Результатом будет созданный объект rv_discrete, который, при помощи вызова метода rvs() можно использовать в качестве генератора. На рис. 10 приведены полученные в ходе построения модели графики распределения вероятностей по уровням интенсивности шумового сигнала.

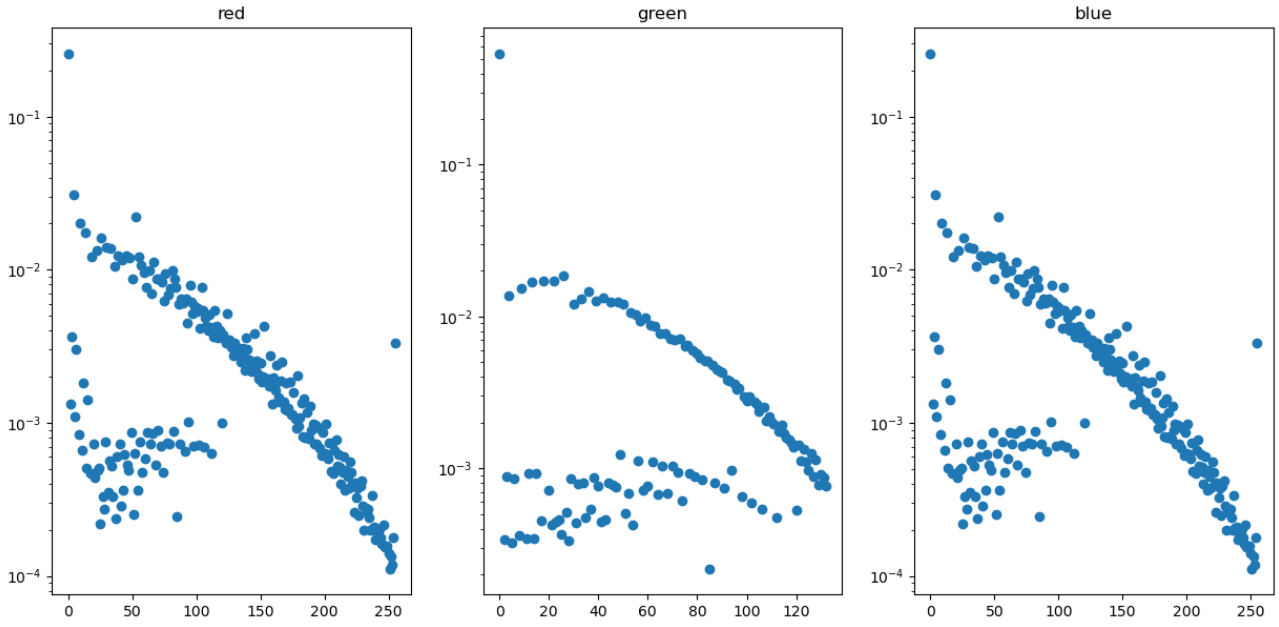

Рисунок 10. Картина распределения шума - диаграмма вероятность/интенсивность

В качестве проверки построенным генератором были смоделированы 10.000 образцов и используя их как исходные данные были проделаны все те же шаги, что и при построении генератора. Полученные в результате графики распределения вероятностей интенсивности приведены на рис ; как можно видеть, полученные модельные результаты практически не отличаются от исходного шума.

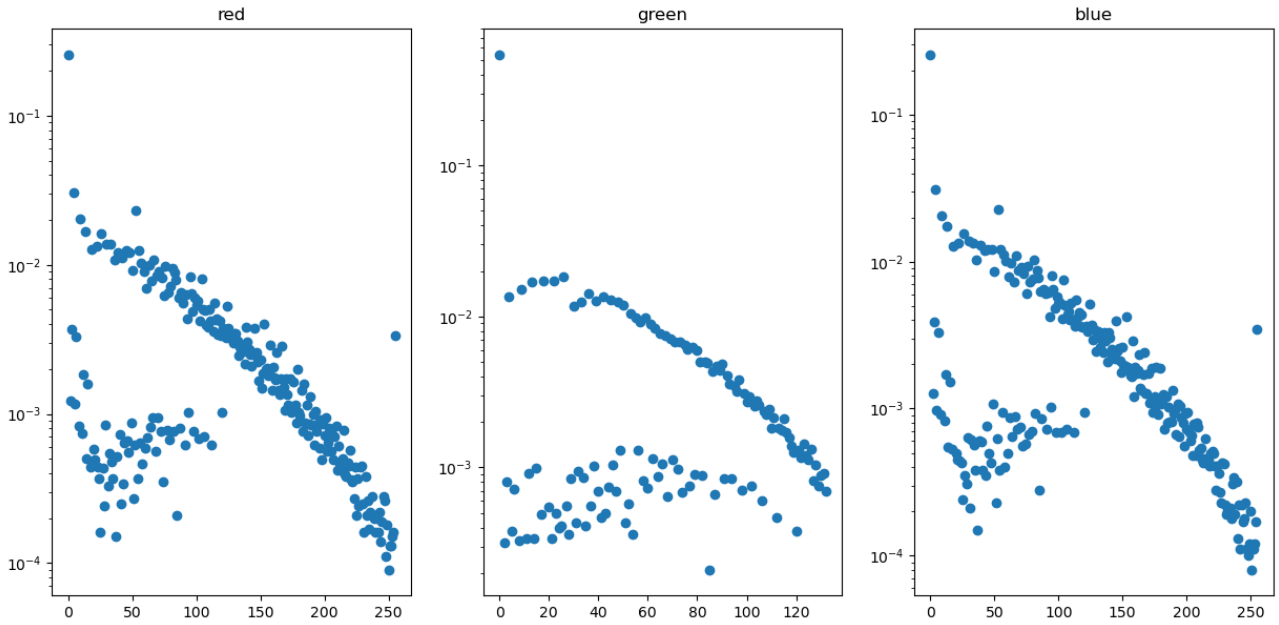

Рисунок 11. Диаграмма вероятность/интенсивность, построенная для смоделированных данных.

Далее, используя построенную модель были сформированы наборы зашумленных изображений с добавочным коэффициентом, равным 0.35. Подбор конкретного значения осуществлялся эмпирически, ориентируясь на получаемый уровень шумов, близкий к таковому для реальных фото, сделанных в плохих условиях освещения и с высоким ISO.

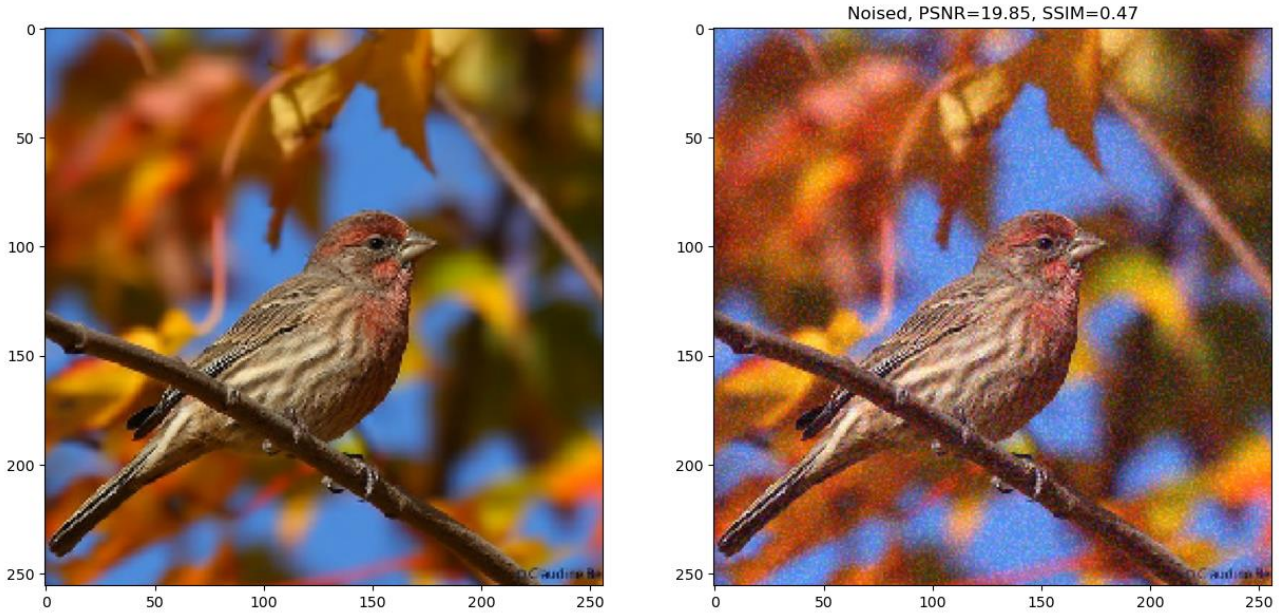

Рисунок 12. Исходное изображение и изображение, зашумленное с применением построенной модели

2.6.4 Обучение сети на модели реального шума

Исходный код – файл dncnn_res_final_real_noise.ipynb.

Сеть, показавшая наилучший результат по итогам второго этапа работы – модификация dnCNN - была обучена на датасете, подготвленном с применением построенной модели реального шума: фнкция потерь SSIM_L2, число эпох – 40, lerning rate – 0.01, обучающая/тестовая выборки составили 2000 и 500 изображений соответственно, валиадационная выборка – 1000. График динамики обучения показан на рис. Ошибка на конец обучения составила 0.0707 на обучении и 0.0691 на валидации.

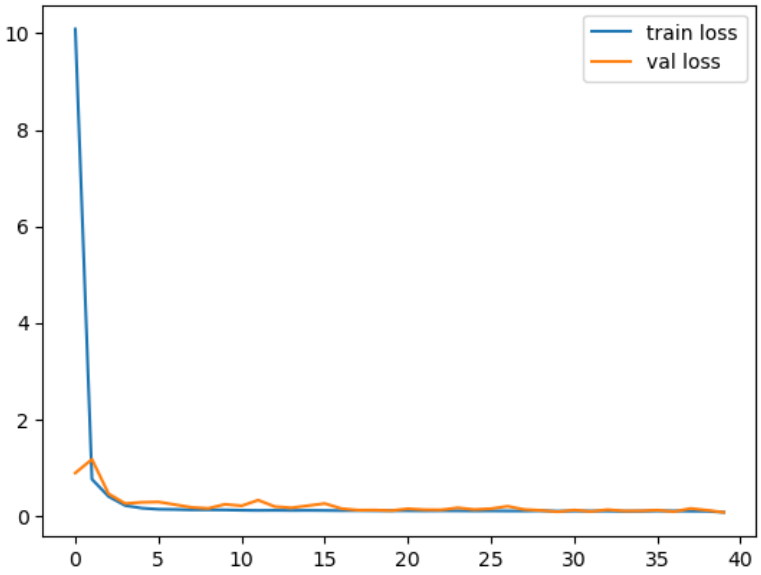

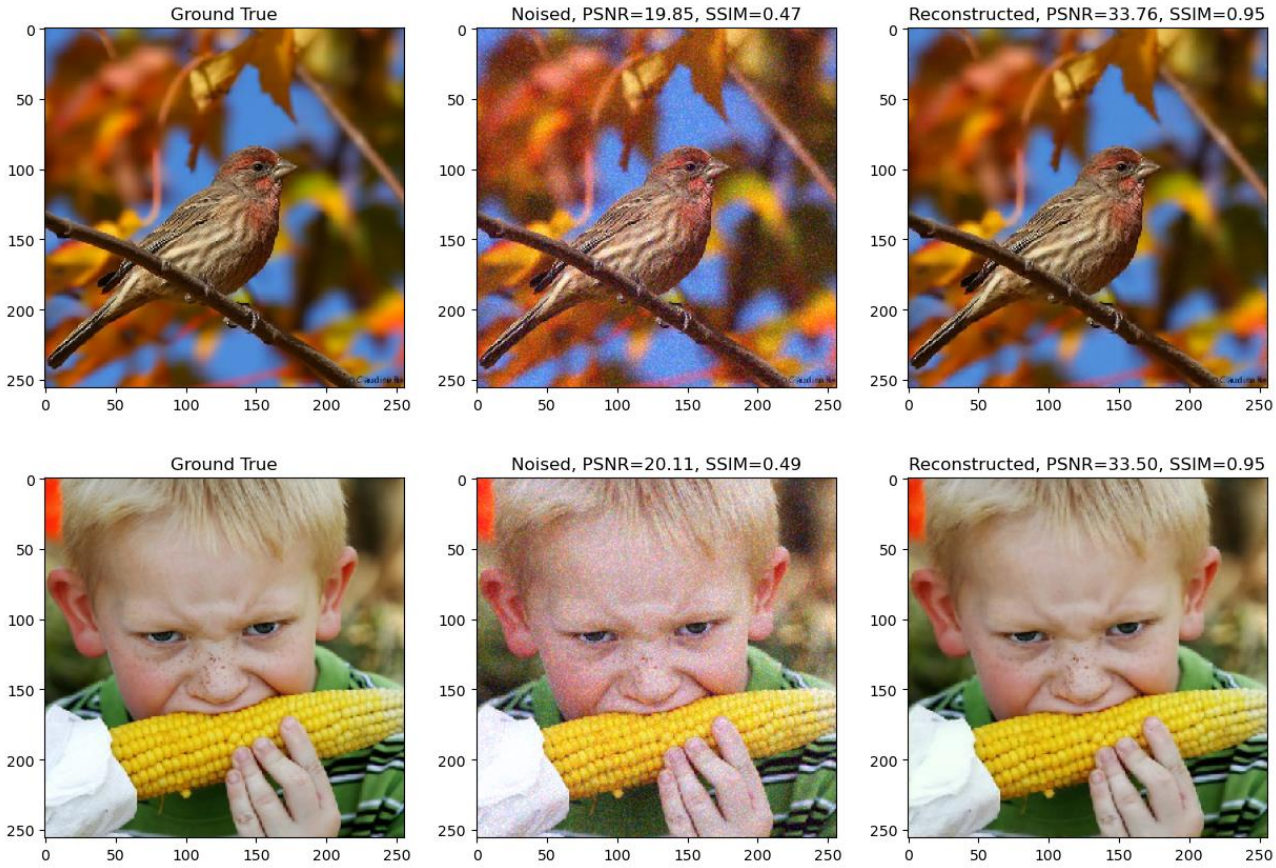
Ground True
Noised, PSNR=19.85, SSIM=0.47
Reconstructed, PSNR=33.76, SSIM=0.95
Ground True
Noised, PSNR=20.11, SSIM=0.49
Reconstructed, PSNR=33.50, SSIM=0.95

Заключение

Библиографический список

1 Kai Zhang, Wangmeng Zuo, Yunjin Chen, Deyu Meng, Lei Zhang. - Beyond a Gaussian Denoiser: Residual Learning of Deep CNN for Image Denoising

2 K. He, X. Zhang, S. Ren, and J. Sun, “Delving deep into rectifiers: Surpassing human-level performance on imagenet classification,” in IEEE International Conference on Computer Vision, 2015, pp. 1026–1034.

3 O. Ronneberger, P. Fischer, and T. Brox. U-Net: Convolutional Networks for Biomedical Image Segmentation. - Springer International Publishing, Cham, 2015. pp. 234-241

4 D. Hendrycks, K. Gimpel, Gaussian Error Linear Units (GELUs) 2016

5 Komatsu, R.; Gonsalves, T. Comparing U-Net Based Models for Denoising Color Images. AI 2020, 1, 465-486. https://doi.org/10.3390/ai1040029

6 Javier Gurrola-Ramos, Oscar Dalmau and Teresa E. Alarcón. A Residual Dense U-Net Neural Network for Image Denoising, IEEE Access, vol. 9, pp. 31742-31754, 2021

7 Hu, Xiaodan, et al. "RUNet: A Robust UNet Architecture for Image Super-Resolution." Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops. 2019

8 Komatsu, R., & Gonsalves, T. Comparing U-Net Based Models for Denoising Color Images., 2020. AI, 1(4), 465–487. https://doi.org/10.3390/ai1040029

9 H. Zhao, O. Gallo, I. Frosio and J. Kautz, "Loss Functions for Image Restoration With Neural Networks," in IEEE Transactions on Computational Imaging, vol. 3, no. 1, pp. 47-57, March 2017, doi: 10.1109/TCI.2016.2644865.